

Faculté des sciences exactes et appliquées
Département informatique
3ème année Licence

Données:
et
Langage XML

Objectifs de la matière : "Données semi-structurées"

Le cours s'intitule «Données semi-stucturées» : étude de format d'échange des données entre applications internet

- Etude de Format polyvalent et ouvert pour représenter des informations : XML (si possible JSON)
- Validation avec un modèle de document : DTD, XML Schema
- API XML : DOM , SAX
- Extraction d'informations à l'aide de requêtes XPath ou XQuery
- Transformation dans un autre format : XSLT ou XQuery

Données : Notions fondamentales

Donné (Data)

- Donnée (Data) : Représentation d'un élément d'information, tel qu'un chiffre ou un fait, codé dans un **format (langage)** permettant son stockage et son traitement par ordinateur.
- Type de donnée (Data type) : Nature du codage utilisé pour représenter une donnée élémentaire et les opérations applicables à cette donnée.
- Les types les plus courants sont : entier, réel, texte, date, image, vidéo, etc

Information

- Information : Une information est une donnée ou un ensemble de données qui a ou ont été interprétée(s)
- Une information est davantage une interprétation de données dans un contexte particulier.
- Information fait référence à la signification d'une donnée mais plus généralement d'un ensemble de données, c'est-à-dire à la sémantique.

Modèle de données

- Modèle de données : Un modèle est une représentation simplifiée d'une réalité
- Un modèle de données est une représentation abstraite des données d'un système. Cette représentation est généralement exprimée à l'aide d'un langage appelé Formalisme (Data model)

Classification des données

- **Données Non-structurées** : Les données non structurées sont des données qui ne sont pas organisées de manière prédéfinie ou qui ne possèdent pas de modèle de données prédéfini.
  - format de représentation basé sur des caractères et des données binaires
- **Données semi-structurées** : Les données semi-structurées ne sont pas (en général) stockées dans une base de données, mais qui possèdent des propriétés organisationnelles facilitant leur analyse.
  - Format : arbre (graphe)
- **Données structurées** : ça concerne toutes les données pouvant être stockées dans une base de données.
  - Format : Tables

Représentation des données : Exemple

Il existe différents formats de représentation des données. Comme exemple illustratif, soient les données suivantes qui décrivent des références bibliographiques :

1. C.C. Marshall and F. M. Shipman. "Which semantic web ?." conference on Hypertext and hypermedia. ACM, 2003
2. A. Michard. XML : langage et applications. Éditions Eyrolles, Paris, 2001

Représentation des données : Exemple

Il existe différents formats de représentation des données. Comme exemple illustratif, soient les données suivantes qui décrivent des références bibliographiques :

1. C.C. Marshall and F. M. Shipman. "Which semantic web ?." conference on Hypertext and hypermedia. ACM, 2003
2. A. Michard. XML : langage et applications. Éditions Eyrolles, Paris, 2001

Différents formalismes peuvent être utilisés pour représenter ces références bibliographiques tel que le langage HTML pour la représentation dans le web, le formalisme de base de données relationnelle et aussi le langage XML.

- HTML :

```
<h1>Bibliographie</h1>
<ul><li>C.C. Marshall and F.M. Shipman,<i>Which semantic web?</i>
, conference on Hypertext and hypermedia.ACM, 2003.
<li>A. Michard,
<i>XML: langage et applications</i>, Editions Eyrolles,2001</ul>
```

- HTML :

```
<h1>Bibliographie</h1>
<ul><li>C.C. Marshall and F.M. Shipman,<i>Which semantic web?</i>
, conference on Hypertext and hypermedia.ACM, 2003.
<li>A. Michard,
<i>XML: langage et applications</i>, Editions Eyrolles,2001</ul>
```

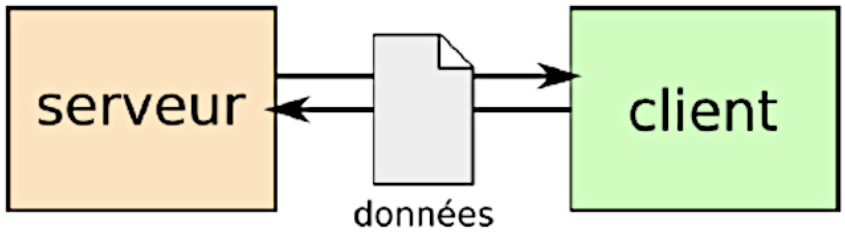
- Table : Base de données relationnelle

Auteur	Titre	Editeur	Conference	Annee
C.C.Marshal	Which semantic web ?	ACM	Hypertext and hypermedia	2003
F.M. Shipman	Which semantic web ?	ACM	Hypertext and hypermedia	2003
A.Michard	XML :langage et applications	Eyrolles	Null	2001

- Langage XML :

```
<?xml version="1.0" encoding="utf-8"?>
<bibliographie>
  <ouvrage annee="2003">
  <auteur>C.C. Marshall</auteur>
  <auteur>F.M. Shipman</auteur>
  <titre>Which semantic web?</titre>
  <conference>Hypertext and hypermedia</conference
    >
  <editeur>ACM</editeur>
  </ouvrage>
  <ouvrage annee="2001">
  <auteur>A.Michard</auteur>
  <titre>XML: langage et applications</titre>
  <editeur>Eyrolles</editeur>
  </ouvrage>
</bibliographie>
```

Le cours s'intitule «Données semi-stucturées» : étude de format d'échange des données entre applications internet



Plusieurs formats existent :

- XML (eXtended Markup Language)
- JSON (JavaScript Object Notation)
- YAML (Yet Another Markup Language)
- CSV (Comma-Separated Values) : Format utilisé pour fichier de type tableur, dont les valeurs sont séparées par des virgules.
- Autres ...

Présentation du langage XML

XML, qu'est-ce que c'est ? (1)

XML :

- e**X**tensible **M**arkup **L**anguage
- Recommandation (norme) du W3C
- Spécifiant un langage
- Constitué d'un ensemble d'éléments appelés balises
- Utilisable pour créer d'autres langages

Conséquences :

- XML est un format de document
- XML est un format de données
- XML est un méta-langage (une famille de langages)

XML, qu'est-ce que c'est ? (2)

- balises descriptives (signification des données) plutôt que procédurales (présentation des données)
- libre, indépendant des plateformes logicielles ou matérielles
- XML est extensible : ne contient pas un ensemble fixé de balises
- les documents XML doivent être bien formés suivant une syntaxe définie, et peuvent donc être formellement validés
- XML est particulièrement adapté à l'échange de données et de documents

Exemple de document XML

Un fichier XML représente des informations structurées :

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <!-- itinéraire fictif -->
3 <itineraire>
4   <etape distance="0km">départ</etape>
5   <etape distance="13km">tourner à droite</etape>
6   <etape distance="22km">arrivée</etape>
7 </itineraire>
```

Le format XML est au coeur de nombreux processus actuels :

- format d'enregistrement de nombreuses applications,
- échange de données entre serveurs et clients,
- outils et langages de programmation,
- bases de données XML natives.

XML en tant que format de fichier

XML est la norme d'enregistrement de nombreux logiciels parmi lesquels on peut citer :

- Bureautique
  - LibreOffice : format OpenDocument
  - Publication de livres et documentations : DocBook
- Graphismes
  - Dessin vectoriel avec Inkscape : format SVG
  - Équations mathématiques : format MathML
- Programmation
  - Interfaces graphiques : Android, XUL (mais le futur WebExtensions est tourné vers JS et JSON)
  - Construction/compilation de projets : Ant, Maven
- Divers
  - Itinéraires GPS : format GPX

Bases de données XML

XML permet aussi de représenter des données complexes.

- Web sémantique : rend les connaissances présentes dans le Web, accessibles à l'aide du modèle RDF représenté par le langage XML.
- Bases de données XML native : les données sont au format XML et les requêtes sont dans un langage (XQuery) permettant de réaliser l'équivalent de SQL.

Échange de données entre clients et serveur

XML est le format utilisé pour représenter des données de nombreux protocoles dont :

- Les flux RSS permettent de résumer les changements survenus sur un site Web.
- Les protocoles XML-RPC et SOAP permettent d'exécuter des procédures à distance.
- Autre exemple : AJAX permet de mettre à jour dynamiquement les pages web sur le navigateur.

Structure d'un document XML

Arborescence d'éléments

Un document XML est composé de plusieurs parties :

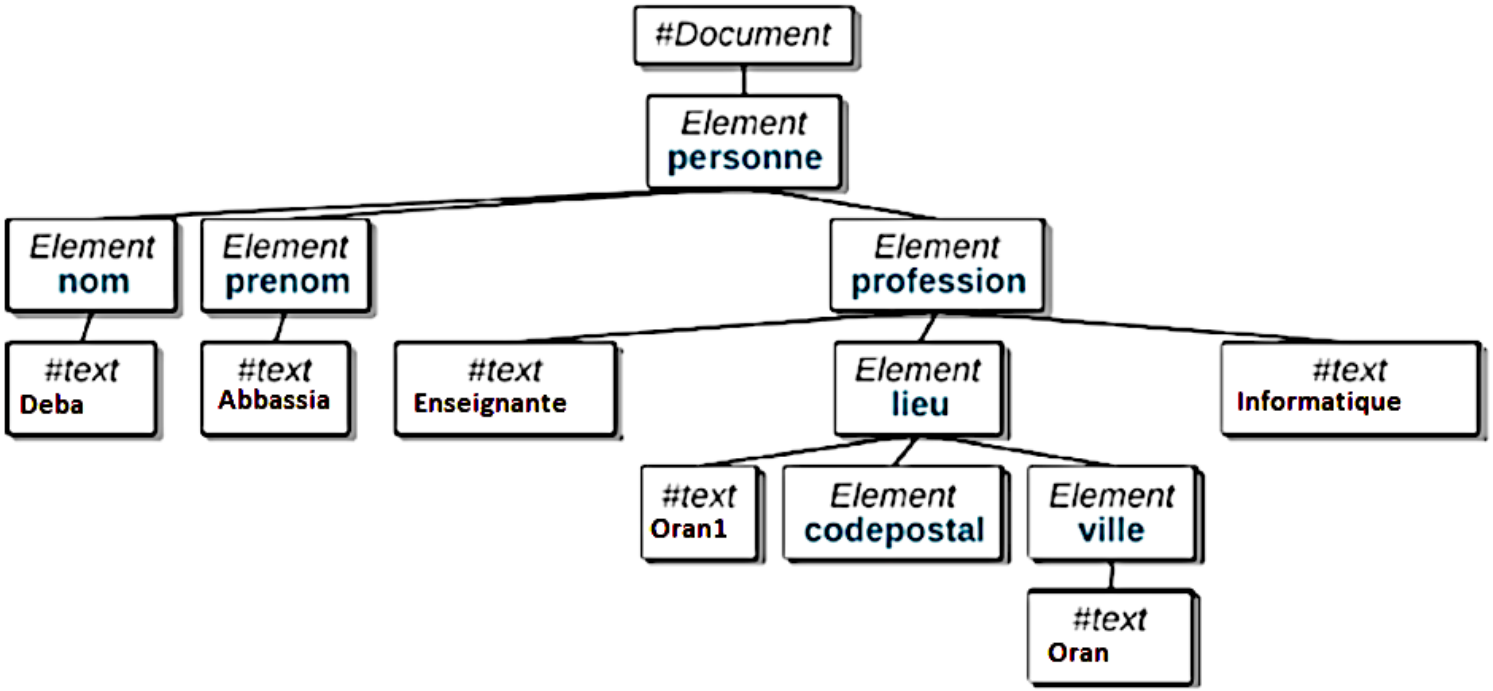
1. **Entête de document** précisant la version et l'encodage,
2. Des **parties optionnelles** de type par exemple : vérifier si le document est valide,
3. **Un arbre d'éléments** basé sur un élément appelé racine
   - Un **élément** possède un **nom**, **des attributs** et un **contenu**
   - Le **contenu d'un élément** peut être :
     - vide : élément vide noté **<nom/>** ou **<nom attributs.../>**
     - du texte
     - d'autres éléments (les éléments enfants).
   - Un **élément non vide** est délimité par une balise ouvrante et une balise fermante.
     - une **balise ouvrante** est notée **<nom attributs...>** ou **<nom attributs...>**
     - une **balise fermante** est notée **</nom>**

Exemple complet

Voici un document XML représentant une personne :

```
1  <?xml version="1.0" encoding="utf-8"?>
2  <!-- ceci est un commentaire -->
3    <personne>
4      <nom>Deba</nom>
5      <prenom>Abbassia</prenom>
6      <profession>enseignante
7        <lieu>Université  Oran1
8          <codepostal/>
9          <ville>Oran</ville>
10       </lieu>
11       informatique
12     </profession>
13   </personne>
```

Représentation graphique



- noeuds Elément ==> ils sont associés aux balises <element>.
- noeuds #text (feuilles de l'arbre) : ils représentent le texte situé entre deux balises.

Syntaxe du langage XML

Prologue XML

- La première ligne d'un document XML est appelée prologue XML.
- Elle spécifie la version de la norme XML utilisée (1.0 ou 1.1 qui sont très similaires) ainsi que l'encodage :
- Exemple :

```
1 <?xml version="1.0" encoding="utf-8"?>
```

```
1 <?xml version="1.0" encoding="iso-8859-15"?>
```

Commentaires XML

- On peut placer des commentaires à peu près partout dans un document XML. La syntaxe est identique à celle d'un fichier HTML.
- Un commentaire peut d'étendre sur plusieurs lignes. La seule contrainte est de ne pas pouvoir employer les caractères – dans le commentaire.
- Exemple :

```
1 <!-- voici un commentaire -->
2
3 ceci n'est pas un commentaire
4 <!--
5   voici un autre commentaire
6   autre ligne.
7 -->
```

Options après le prologue

Après le prologue, on peut trouver plusieurs parties optionnelles délimitées par <? ... ?> ou <! ... >. Ce sont des instructions de traitement, des directives pour l'analyseur XML.

Par exemple :

- un **Document Type Definition** (DTD) qui permet de valider le contenu du document. C'est l'objet du prochain cours.
- une **feuille de style** (à voir plus tard).

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <!DOCTYPE personne SYSTEM "personne.dtd">
3 <?xml-stylesheet href="personne.css" type="text/css"?>
4 <personne>
5 ...
6 </personne>
```

Éléments

Les éléments définissent la structure du document. Un élément est délimité par :

- une balise ouvrante <nom> ou <nom attributs ...>
- une balise fermante </nom> obligatoire.

Le contenu de l'élément se trouve entre les deux balises. Ce sont des éléments enfants et/ou du texte.

```
1 <parent>
2   texte1
3   <enfant>texte2</enfant>
4   texte3
5 </parent>
```

Dans le cas où l'élément n'a pas de contenu (élément vide), on peut regrouper ses deux balises en une seule <nom/>

Noms des éléments

- Les noms des éléments peuvent employer les caractères du codage déclaré dans le prologue mais pas les signes de ponctuation.
- Le premier caractère du nom d'élément doit être une lettre ou le signe _ ensuite, on peut trouver des lettres, des chiffres ou - . _
- Le caractère : permet de séparer le nom en deux parties : préfixe et nom local. Le tout s'appelle **nom qualifié**. Par exemple oran1 :departement est un nom qualifié préfixé par oran1. Ce préfixe permet de définir un espace de nommage.

nom qualifié = préfixe :nom local (voir section espace de nommage)

Attributs

Les attributs caractérisent un élément. Ce sont des couples **nom="valeur"** ou **nom='valeur'**. Ils sont placés dans la balise ouvrante.

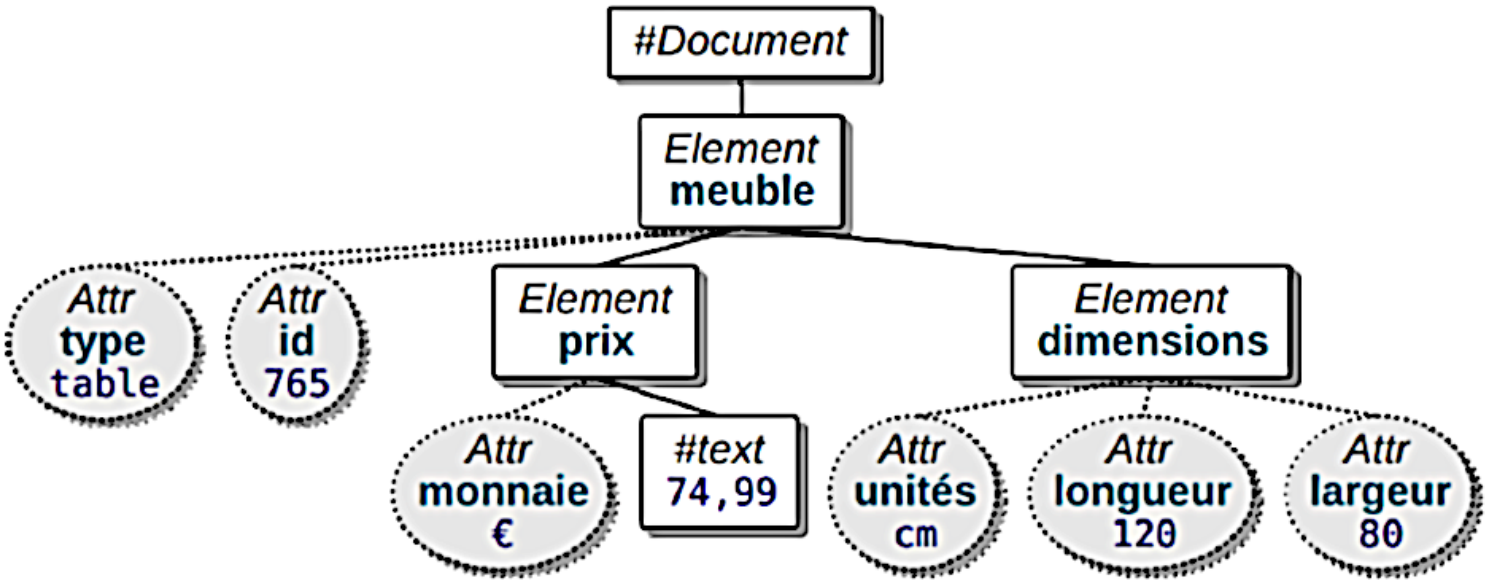
Exemple :

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <meuble id="765" type='table'>
3   <prix monnaie='DZD'>7400,00</prix>
4   <dimensions unites="cm" longueur="120" largeur="80"/
      >
5   <description langue='fr'>Belle petite table</
      description>
6 </meuble>
```

Remarques :

- Il n'y a pas d'ordre entre les attributs d'un élément,
- Un attribut ne peut être présent qu'une fois.

Attributs dans l'arbre du document



Entités

- Certains caractères sont interdits dans le contenu des éléments. Comme il est interdit de les employer, XML propose une représentation appelée référence d'entité ou entité pour simplifier.
- On retrouve le même concept en HTML.

Caratère	Entité
<	&lt ;
>	&gt ;
&	&amp ;
'	&apos ;
"	&quot ;

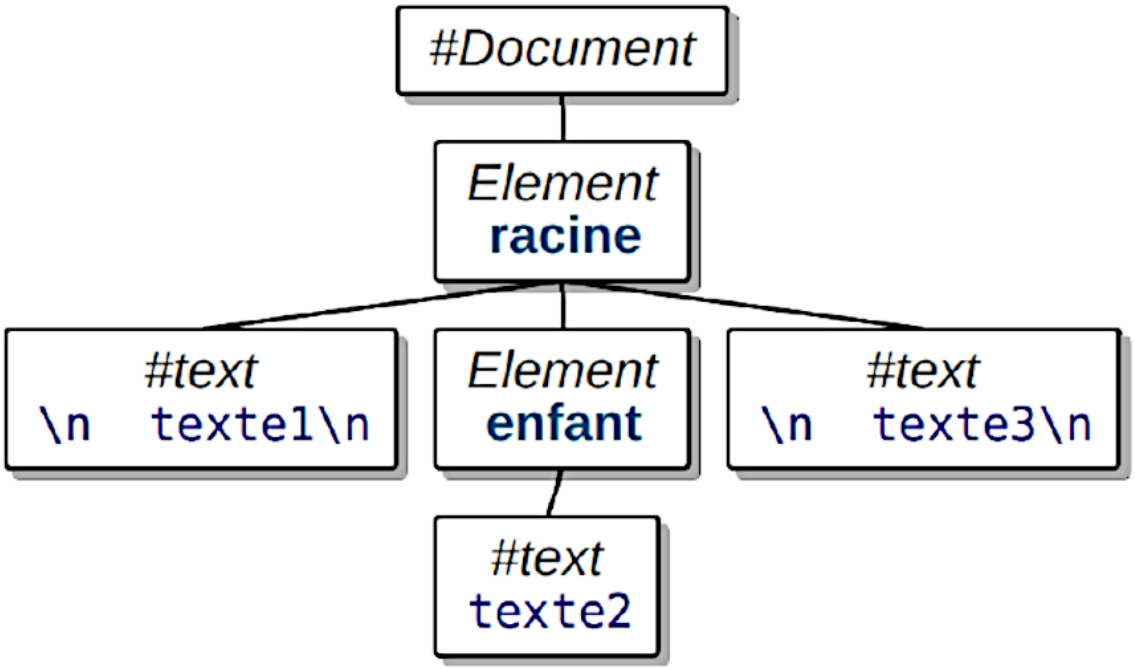
Texte

Les textes font partie du contenu des éléments et sont vus comme des noeuds enfants. Il faut bien comprendre que la totalité du texte situé entre les balises, y compris les espaces et retour à la ligne font partie du texte.

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <racine>
3 texte1
4 <enfant>texte2</enfant>
5 texte3
6 </racine>
```

Arbre correspondant

Voici l'arbre correspondant à l'exemple précédent. Notez les retours à la ligne et espaces présents dans les textes sauf texte2.



Sections CDATA

- Lorsqu'on veut écrire du texte brut à ne pas analyser en tant qu'XML, on emploie une section CDATA :
- Exemple :

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <fichier>
3 <nom>exemple1.xml</nom>
4 <md5><![CDATA[19573b741c0c5c8190a83430967bfa58]]><
      /md5>
5 </fichier>
```

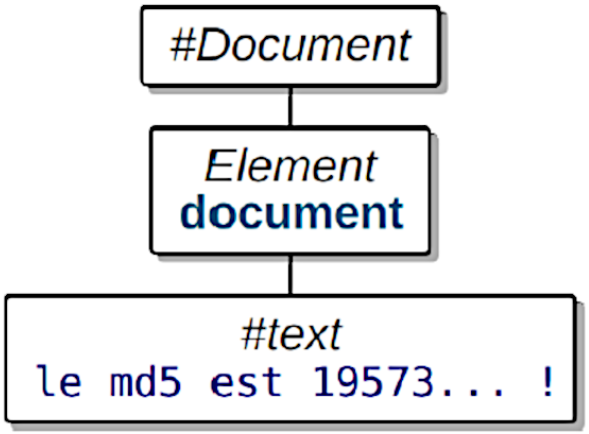
- La partie entre <![CDATA[et]]> est ignorée par les analyseurs XML, on peut mettre n'importe quoi sauf]]>. Ces données sont considérées comme du texte par les analyseur.

Fusion des CDATA et textes

S'il y a des textes avant ou après une section CDATA, ils sont tous fusionnés avec elle.

Exemple :

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <document>le md5 est <![CDATA[19573...]]> !</document>
```



Document bien formé (1)

Un document XML est bien formé (well-formed), s'il respecte les règles de la syntaxe XML :

1. Un document XML doit contenir :
   - Une déclaration XML,
   - Un ou plusieurs éléments,
   - Un élément racine encapsulant tous les autres éléments et leurs attributs
2. Eléments :
   - Les éléments non vides ont une balise de début et de fin,
   - Sont correctement imbriqués <P> <EM> ... </EM> </P>
   - Les éléments vides ont un / à la fin de la balise,
   - Les noms des balises ouvrantes et fermantes correspondent.

Document bien formé (2)

3. Attributs :
   - Un nom d'attribut n'apparaît que dans la balise ouvrante et une seule fois,
   - Les valeurs des attributs sont entre guillemets ou apostrophes,
   - La valeur des attributs n'appelle pas d'entités externes

Espaces de nommage

A quoi sert un espace de nommage ?

- Un espace de nommage (namespace) définit une famille de noms afin d'éviter les confusions entre des éléments qui auraient le même nom mais pas le même sens. Cela arrive quand le document XML modélise les informations de plusieurs domaines.
- Voici un exemple dans le domaine de la vente de meubles. Le document modélise une table (avec 4 pieds) et aussi un tableau HTML pour afficher ses dimensions. On voit la confusion.

Exemple :

```
<meuble id="765">
<table prix="74,99">acajou</table>
<table border="1">
<tr><th>longueur</th><th>largeur</th></tr>
<tr><td>120cm</td><td>80cm</td></tr>
</table>
```

Définition d'un espace de nommage (1)

- Un URI est utiliser pour identifier l'espace de nommage.
- URI (Uniform Ressource Identifier) : permet de référencer une ressource.
- Ressource : est un objet concret (page web, répertoire web,..) ou abstrait (sans existence réelle).
- Exemples d'URI :
  ftp ://ftp.univ-oran.dz/pub/
  http ://www.univ-oran.dz/ws.html
  mailto :F.kateb@gmail.com
  telnet ://193.55.30.2
  urn :mimetype :application/pdf

Définition d'un espace de nommage (2)

- Un URI est généralement un URL. Ensuite on rajoute un attribut spécial à la racine du document :

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <racine xmlns:PREFIXE="URI">
3   <PREFIXE:balise>...</PREFIXE:balise>
4 </racine>
```

Exemple corrigé

Voici l'exemple précédent, avec deux namespaces, un URN pour les meubles et un URL pour HTML :

```
<?xml version="1.0" encoding="utf-8"?>
<meuble:meuble id="765" xmlns:meuble="
    urn:iutlan:meubles"
            xmlns:html="http://www.w3.org">
<meuble:table prix="74,99">acajou</meuble:table>
  <html:table border="1">
  <html:tr><html:th>longueur</html:th>...</html:tr>
  <html:tr><html:td>120cm</html:td>...</html:tr>
  </html:table>
</meuble:meuble>
```

Notez le préfixe également appliqué à la racine du document.

Namespace par défaut

- Lorsque la racine du document définit un attribut xmlns="URI", alors par défaut toutes les balises du document sont placées dans ce namespace, donc pas besoin de mettre un préfixe.

```
<?xml version="1.0" encoding="utf-8"?>
<book xmlns="http://docbook.org/ns/docbook">
```

- Ça peut s'appliquer également localement à un élément et ça concerne toute sa descendance :

```
<meuble id="765" xmlns="urn:iutlan:meubles">
  <table prix="74,99">acajou</table>
  <table border="1" xmlns="http://www.w3.org">
    <tr><th>longueur</th>...</tr>
    <tr><td>120cm</td>...</tr>
  </table>
</meuble>
```

Ressources à consulter

Références

- Sites web :
  - W3 Consortium : http ://www.w3.org - Site : http ://www.w3schools.com

- Michard, Alain, 2001. XML. Langage et applications, Eyrolles.